

Робастное безградиентное модельно-прогнозирующее управление автономными роботами с онлайн-адаптацией динамической модели

Рабочее название: Robust Gradient-Free Model Predictive Control for Autonomous Robots with Online Model Adaptation.

Структура работы:

ВВЕДЕНИЕ

Актуальность задач оптимального управления автономными роботами в условиях неопределенности среды и неточных моделей динамики продолжает расти. Классические градиентные методы (например, дифференциальное динамическое программирование — DDP) и традиционное модельно-прогнозирующее управление (МПУ) сталкиваются с ограничениями при работе с нелинейными системами, недифференцируемыми функциями стоимости и ограничениями. Безградиентный метод Model Predictive Path Integral (MPPI) управления предлагает мощную альтернативу, генерируя ансамбли стохастических траекторий, оценивая их стоимость и взвешенно усредняя управления без вычисления градиентов. Это позволяет эффективно работать со сложной нелинейной динамикой и произвольными функциями стоимости, используя параллельные вычисления на GPU.

Однако эффективность MPPI критически зависит от точности используемой прогнозной модели динамики: $x_{t+1} = f(x_t, u_t)$. Рассогласование между предсказаниями модели и реальным поведением робота приводит к неверной оценке стоимости траекторий, деградации качества управления и потере робастности, особенно в нестационарных или плохо идентифицируемых условиях (изменение массы, трения, повреждения).

Существующие подходы к повышению робастности МРПИ (Robust МРПИ¹, Planner-Estimator МРПИ²) в основном фокусируются на учете неопределенности в рамках фиксированной модели или адаптации ее параметров. Данная работа предлагает иной подход: онлайн-адаптацию самой структуры прогнозной модели на основе постоянного сравнения предсказанных траекторий с фактическими данными датчиков. Гипотеза заключается в том, что такая адаптация позволит динамически подстраивать модель под изменяющиеся условия, существенно повышая робастность базового МРПИ.

Целью работы является разработка, программная реализация и экспериментальная проверка модифицированного алгоритма МРПИ с интегрированным механизмом онлайн-адаптации прогнозной модели динамики робота.

Задачи:

1. Проанализировать ограничения стандартного МРПИ и существующих робастных модификаций в контексте чувствительности к модели.
2. Разработать архитектуру адаптивного МРПИ, включающей блок онлайн-адаптации модели на основе данных о реальной динамике.
3. Выбрать и обосновать метод адаптации модели (рассматриваются: онлайн-дообучение нейронной сети, адаптивные гауссовы процессы, ансамбли локальных моделей).

¹ Gandhi M. S. и др. Robust model predictive path integral control: Analysis and performance guarantees // IEEE Robotics and Automation Letters. 2021. Т. 6. №. 2. С. 1423-1430.

² Raisi M., Noohian A., Fallah S. A fault-tolerant and robust controller using model predictive path integral control for free-flying space robots // Frontiers in Robotics and AI. 2022. Т. 9. С. 1027918.

4. Практическая реализация алгоритма с использованием GPU для вычислений MPPI и эффективной интеграции блока адаптации.
5. Экспериментальное исследование на платформе автономного роботоманипулятора или мобильного робота: сравнение робастности и точности управления базового MPPI и адаптивного MPPI в сценариях с изменением динамики (масса, трение, повреждение).

1. Теоретические основы и анализ существующих методов MPPI

1.1. Алгоритм Model Predictive Path Integral Control (MPPI)

Метод MPPI представляет собой стохастическую схему оптимального управления без вычисления градиентов³. На каждом шаге управления:

1. Генерируется K возмущений для управляющей последовательности:

$$\delta u^{(k)} \sim N(0, \Sigma), (k = 1..K)$$

вокруг номинального управления u^{nom} .

2. Каждая возмущенная последовательность:

$$u^{(k)} = u^{nom} + \delta u^{(k)}$$

вычисляется вперед на горизонт T с использованием модели динамики:

$$x_{t+1} = f(x_t, u_t),$$

формируя траекторию состояния τ_k .

3. Для каждой траектории вычисляется интегральная стоимость:

$$S(\tau_k) = \varphi(x_T) + \sum_{k=0}^{T-1} q(x_t, u_t),$$

где φ – терминальная стоимость, q – промежуточная стоимость.

³ Williams G. и др.. Model predictive path integral control: From theory to parallel computation //Journal of Guidance, Control, and Dynamics. 2017. Т. 40. №. 2. С. 344-357.

4. Тракториям присваиваются веса:

$$\omega_k = \exp\left(-\frac{S(\tau_k)}{\lambda}\right),$$

где λ – параметр "температуры" (меньшая стоимость означает больший вес).

5. Оптимальное управление на текущем шаге вычисляется как взвешенное среднее возмущений:

$$u_t = u_t^{nom} + \frac{\sum_{k=1}^K \omega_k \cdot \delta u_t^{(k)}}{\sum_{k=1}^K \omega_k}$$

Ключевые преимущества: отсутствие требования дифференцируемости f и S , способность работать с нелинейностями и сложными ограничениями (через S), естественный параллелизм (вычисление траекторий независимо). Вычислительная сложность определяется числом траекторий K и длиной горизонта T . Основным ограничением является критическая зависимость от точности модели f . Неточности модели приводят к:

- Ошибкам в предсказанных траекториях τ_k .
- Неверному расчету стоимостей $S(\tau_k)$.
- Неадекватным весам ω_k (полезные траектории могут получать малый вес, плохие — большой).
- Деградации или потере управляемости.

1.2. Постановка задачи адаптации модели в MPPI

Анализ показывает, что Robust MPPI учитывает неопределенность, но не адаптирует модель. PE-MPPI адаптирует параметры, но предполагает

верную структуру модели. В реальных сценариях (изменение трения, повреждения, сложные взаимодействия) может требоваться адаптация самой структуры прогнозной модели. Задача данной работы: Разработать алгоритм МРРІ с онлайн-адаптацией прогнозной модели f на основе потока данных $(u_{t-N}, \dots, u_{t-1}, x_{t-N+1}^{real}, \dots, x_t^{real})$, позволяющей уточнять модель в реальном времени для повышения робастности управления в условиях значительного и изменяющегося рассогласования.

2. Разработка и практическая адаптивного алгоритма МРРІ

2.1. Архитектура адаптивного МРРІ

Предлагаемая система адаптивного управления строится вокруг модифицированной архитектуры МРРІ, где ключевым компонентом становится блок онлайн-адаптации динамической модели. Ядро системы образует стандартный алгоритм МРРІ, который использует текущее состояние робота x_t и актуальную адаптивную модель f_{adapt} для генерации управляющих воздействий u_t . Для обеспечения обратной связи система интегрирует датчики состояния, фиксирующие реальное положение робота $(x_{t-N+1}^{real}, \dots, x_t^{real})$, после применения сгенерированных команд.

Собранные данные о фактическом поведении системы сохраняются в специализированном буфере, хранящем кортежи вида $(u_{t-N}, \dots, u_{t-1}, x_{t-N+1}^{real}, \dots, x_t^{real})$, за последние N шагов по принципу скользящего окна. На основе этого исторического блока функционирует модуль адаптации, который периодически обновляет прогнозную модель f_{adapt} . Для реализации адаптации рассматриваются три основных подхода: онлайн-дообучение легковесных нейронных сетей (MLP или RNN) с контролем переобучения через регуляризацию и малую скорость обучения; адаптивные Гауссовы процессы с аппроксимациями для онлайн-режима; а также ансамбли локальных моделей типа LWPR/GMR, динамически обновляющих свои

параметры. Обновленная модель передается в блок MPPI, заменяя предыдущую версию и обеспечивая более точное прогнозирование траекторий.

2.2. Ключевые аспекты реализации

Практическая реализация алгоритма требует проектирования вычислительной инфраструктуры. Основой платформы выступает бортовой GPU, обеспечивающий параллельный расчет траекторий MPPI. Программный стек включает комбинацию Python/C++, фреймворки для GPU-ускорения (PyTorch, CUDA) и middleware ROS для интеграции с сенсорами и исполнительными системами робота.

2.3. План экспериментальной оценки

Экспериментальная валидация алгоритма запланирована на платформе автономного мобильного колесного робота, оснащенного бортовым GPU и комплексом датчиков состояния (одометрия, IMU).

Ход эксперимента:

На данный момент исследуется работа классического MPPI с условием рассогласования модели динамики робота с реальным воздействием на него (путем добавления внешней силы, неучтенной в модели).

$$x_{i+1} = f(x_i, u_i) + h(x_i, u_i, p_i),$$

где x_i – переменная состояния, u_i – управляющий сигнал, p_i – записанные предыдущие состояния, $f(x_i, u_i)$ – функция динамики, $h(x_i, u_i, p_i)$ – функция неучтенной динамики (невязка). Данные симуляции (рис. 1) проходят оффлайн, в дальнейшем планируется их перевод на тензорные вычисления и GPU. Следующим шагом эксперимента станет введение в метод невязки между реально пройденной траекторией и траекторией из предсказания. Если в систему управления будет включен компонент, отвечающий за рассогласование модели и реальности, и это приведет по крайней мере к

минимизации эффекта от неучтенной динамики, то экспериментальные исследования продолжатся с фокусом на доработку метода и написание теоретической части, в противном случае – будет проверяться альтернативная гипотеза того, как можно учесть рассогласование и минимизировать его эффект.




Рис. 1. Текущее окно симуляции робота.

На данный момент:

- Проведен первичный обзор литературы для погружения в проблему
- Существует 2 гипотезы о возможном улучшении метода МРРІ
- Есть симулятор, позволяющий проводить симуляции, а также найдены имплементации, для адаптации вычислений на GPU
- Сейчас получено сравнение версий контроллера, который имеет полную модель среды и модель, не учитывающую внешнюю силу, которую можно регулировать

ЗАКЛЮЧЕНИЕ (предварительно)

Ожидается, что разработанный алгоритм МРРІ с онлайн-адаптацией модели продемонстрирует существенно более высокую робастность по сравнению со стандартным МРРІ в условиях намеренно внесенного рассогласования модели и изменений динамики робота. Будет подтверждена работоспособность концепции адаптации структуры модели в реальном времени на бортовой вычислительной платформе. Полученные результаты обоснуют перспективность подхода для управления автономными роботами в сложных и нестационарных условиях. Дальнейшая работа будет включать тестирование на более сложных платформах (дроны), исследование гибридных методов адаптации и оптимизацию вычислительной эффективности.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Andrejev E. M. et al. π -MPPI: A Projection-based Model Predictive Path Integral Scheme for Smooth Optimal Control of Fixed-Wing Aerial Vehicles // IEEE Robotics and Automation Letters. – 2025.
2. Gandhi M. S. и др. Robust model predictive path integral control: Analysis and performance guarantees // IEEE Robotics and Automation Letters. 2021. Т. 6. №. 2. С. 1423-1430.
3. Minařík M. и др. Model predictive path integral control for agile unmanned aerial vehicles // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024. С. 13144-13151.
4. Raisi M., Noohian A., Fallah S. A fault-tolerant and robust controller using model predictive path integral control for free-flying space robots // Frontiers in Robotics and AI. 2022. Т. 9. С. 1027918.
5. Wang Z. и др. Variational inference MPC using Tsallis divergence // arXiv preprint arXiv:2104.00241. 2021.
6. Williams G. и др. Model predictive path integral control: From theory to parallel computation // Journal of Guidance, Control, and Dynamics. 2017. Т. 40. №. 2. С. 344-357.
7. Xue H. и др. Full-order sampling-based mpc for torque-level locomotion control via diffusion-style annealing // arXiv preprint arXiv:2409.15610. 2024.

Обзор литературы

Исходная работа. Метод MPPI впервые был предложен Уильямсом и др. в 2016 г. (ICRA 2016). В этой работе представлены теоретические основы, описан алгоритм с GPU параллелизацией и проведено сравнение с MPC-DDP (дифференциальным динамическим программированием). Авторы показали, что MPPI благодаря безградиентному стохастическому поиску лучше учитывает нелинейности и позволяет использовать произвольные функции стоимости, а также превосходит DDP в некоторых сложных задачах (например, внедорожная езда).

Устойчивость к помехам (RMPPI). Gandhi et al. предложили Robust MPPI (RAL 2021) – архитектуру, учитывающую несоответствия модели и использующую параллельные треки «номинального» и «реального» состояний. RMPPI обеспечивает гарантии по нарушению функций стоимости и комбинирует агрессивное и консервативное поведение. В экспериментах на внедорожном роботе показано, что RMPPI выигрывает у стандартного MPPI и Tube-MPPI по сочетанию производительности и робастности.

Снижение дисперсии (Tsallis-MPPI). В RSS 2021 была представлена версия MPPI на основе дивергенции Цаллиса (Tsallis VI-MPC). Этот подход вводит гиперпараметр «доли элитного множества» и позволяет объединять методы СЕМ (метод кроссэнтропии) и MPPI. В работе показано, что Tsallis-MPPI даёт лучшие средние результаты и меньшую дисперсию стоимостей по сравнению со стандартным MPPI и СЕМ, особенно в сложных высокоразмерных задачах. Иначе говоря, использование статистики Цаллиса помогает управлять распределением сэмплованных траекторий и улучшает надёжность.

Сглаживание и другие улучшения. Для снятия «рывков» управления введены различные модификации. Например, π -MPPI (IROS 2023) включает проекцию с помощью фильтра на траектории управления (высшие производные), что даёт более гладкий сигнал. Tube-MPPI (RSS 2018) и другие варианты добавляют жёсткие ограничения на неопределённость и гарантии

соблюдения траектории. Кроме того, рассматриваются обобщения на нелинейную стохастику, многозадачные системы и т.д. (например, МРРІ применяют в системе распределённого управления и активного вывода, многомодальные МРРІ).

МРРІ контроллер для БПЛА. Авторы (Minarik, Penicka, Vonasek, Saska) представляют МРРІ-контроллер, предназначенный для агрессивного полета UAV в условиях плотной среды (пролеты через узкие окна, высокая скорость, быстрые манёвры), при этом расчёт выполняется полностью на борту на GPU (Jetson Orin Nano) с частотой ~ 100 Гц и без помощи внешних компьютеров. Это первый известный пример применения МРРІ вживую на БПЛА, достигая скорости до 44 км/ч и ускорения ~ 20 м/с², с одновременным учётом динамики и избеганием препятствий.

Двойной отжиг (DIAL-MPC). Метод DIAL-MPC, предложенный Hue et al. оптимизирует полную динамическую модель ходячего робота (на уровне крутящих моментов) без прибегания к упрощениям модели. Мотивация — обеспечить эффективный онлайнконтроль в высокоразмерных контактно-динамических системах, где классический NMPC с полной моделью слишком медлителен, а стандартный МРРІ при фиксированной дисперсии часто застревает в локальных оптимумах. DIAL-MPC вводит «диффузионно-стильный отжиг»: управление итеративно уточняется от размытых приближений к истинной целевой функции. Иными словами, сначала оптимизируется усреднённый (сглаженный) вариант задачи, а затем постепенно возвращается к исходному $J(u)$. В результате достигается баланс между глобальным исследованием пространства управления и сходимостью к оптимуму. Эксперименты показывают, что DIAL-MPC на квадрупеде уменьшает ошибку траектории в $\sim 13.4\times$ по сравнению со стандартным МРРІ и превосходит RL-подходы примерно на 50% в сложных задачах (например, лазании с нагрузкой) без обучения. В частности, метод позволяет точно выполнять прыжки квадрупеда с дополнительной нагрузкой. По утверждению

авторов, DIAL-MPC — первый train-free метод, который в реальном времени оптимизирует полную (18 DOF) модель квадрупеда на уровне крутящих моментов.

Planner-Estimator MPPI. В статье Raisi, Noohian и Fallah (2022) представлен Planner-Estimator MPPI (PE-MPPI) — расширение классического MPPI, специально адаптированное для свободноплавающих космических робототехнических манипуляторов (free-flying space robots) при наличии отказов и параметрической неопределённости. MPPI чувствителен к несовпадению между моделью и реальной динамикой. При неправильных параметрах модельных roll-outs, веса траекторий обнуляются, и управление становится неэффективным. Оценщик компенсирует это, обновляя модель так, чтобы планировщик получал более точное предсказание. В статье показано, что PE-MPPI остается стабильным и точным даже при отказе приводов и резком изменении массы в фазе pre-capture миссии по удалению мусора.