

**Автономная некоммерческая организация высшего образования
«Университет Иннополис»
(АНО ВО «Университет Иннополис»)**

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ)
по направлению подготовки
09.04.01 Информатика и вычислительная техника**

**Направленность (профиль) образовательной программы
«Робототехника и компьютерное зрение»**

Тема

--

Работу выполнил

--

подпись

**Руководитель
выпускной
квалификационной
работы**

--

подпись

Консультанты

--

подпись

Иннополис, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Обзор литературы	11
2 Методология.....	21
3 Экспериментальные исследования	32
ЗАКЛЮЧЕНИЕ	39
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	42

ВВЕДЕНИЕ

Развитие автономных робототехнических систем является одним из наиболее значимых направлений современной инженерии. Мобильные роботы, беспилотные автомобили, летательные аппараты, складские платформы и сервисные роботы все чаще используются в задачах, где требуется самостоятельное движение в сложной и частично неопределенной среде. Для таких систем недостаточно заранее задать фиксированную последовательность управляющих воздействий, поскольку условия движения могут изменяться, модель объекта может быть неточной, а внешние возмущения могут приводить к отклонению от запланированной траектории. Поэтому одной из ключевых задач автономной робототехники является разработка методов управления, способных в реальном времени учитывать текущее состояние системы, прогнозировать ее дальнейшее поведение и выбирать управляющие воздействия, обеспечивающие движение к заданной цели.

Особое значение в этом контексте имеют методы предиктивного управления. В отличие от классических регуляторов, которые формируют управляющее воздействие преимущественно на основе текущей ошибки, методы Model Predictive Control (MPC) используют модель динамики объекта для прогнозирования поведения системы на конечном горизонте времени. На каждом шаге управления решается задача оптимизации, в которой выбирается такая последовательность управляющих воздействий, которая минимизирует заданную функцию стоимости. После этого к системе применяется только первое управляющее воздействие из найденной последовательности, горизонт предсказания сдвигается вперед, и процедура повторяется. Благодаря этому MPC естественным образом подходит для задач слежения за траекторией, обхода препятствий, учета ограничений на управление и состояния, а также для работы с нелинейной динамикой.

Актуальность темы исследования обусловлена необходимостью повышения надежности автономных робототехнических систем при работе в условиях неполной и неточной информации о динамике объекта. В практических задачах модель, используемая контроллером, почти всегда отличается от реальной системы, а накопление ошибки прогноза может приводить к ухудшению точности следования траектории и снижению устойчивости движения. Поэтому разработка методов предиктивного управления, способных адаптироваться к ошибкам модели в процессе работы, является важной задачей современной робототехники.

Однако применение классических вариантов MPC в робототехнических задачах часто связано с рядом трудностей. Во-первых, динамика реальных робототехнических систем, как правило, является нелинейной. Во-вторых, функции стоимости могут включать негладкие штрафы, ограничения безопасности, препятствия и другие элементы, затрудняющие применение градиентных методов оптимизации. В-третьих, для работы в реальном времени алгоритм управления должен быть достаточно быстрым, поскольку управляющее воздействие необходимо пересчитывать на каждом шаге движения. Эти обстоятельства мотивируют использование стохастических и безградиентных методов предиктивного управления, в которых оптимизация выполняется не за счет аналитического вычисления градиентов, а за счет случайной выборки множества возможных траекторий.

Одним из наиболее известных методов такого класса является Model Predictive Path Integral Control (MPPI). Данный подход основан на генерации множества случайных rollout-траекторий, получаемых путем добавления шумовых возмущений к номинальной последовательности управления. Каждая траектория оценивается с помощью функции стоимости, после чего управляющая последовательность обновляется как взвешенное среднее случайных возмущений. Траектории с меньшей стоимостью получают больший вес, а траектории с высокой стоимостью оказывают меньшее влияние

на итоговое управление. Благодаря такой структуре МРРІ не требует дифференцирования модели динамики и функции стоимости, хорошо подходит для параллельных вычислений и может применяться к широкому классу нелинейных систем.

В робототехнике МРРІ привлекателен тем, что позволяет работать с достаточно сложными постановками задач. В функцию стоимости могут быть включены штрафы за отклонение от траектории, за столкновение с препятствиями, за нарушение ограничений, за резкие управляющие воздействия и другие практически важные критерии. При этом сам алгоритм сохраняет относительно простую структуру: на каждом шаге он многократно моделирует возможное будущее поведение системы и выбирает управление на основе статистической оценки качества этих вариантов. Такая особенность делает МРРІ удобным для задач автономного движения мобильных роботов, беспилотных автомобилей и летательных аппаратов.

Несмотря на эти преимущества, качество работы МРРІ существенно зависит от точности модели динамики, используемой при построении rollout-траекторий. Именно модель определяет, какие будущие состояния будут предсказаны для каждой последовательности управляющих воздействий. Если модель совпадает с реальной системой достаточно хорошо, то значения функции стоимости корректно отражают ожидаемое качество движения. Если же модель содержит систематическую ошибку, то предсказанные траектории становятся смещенными. В этом случае алгоритм может выбирать управление, которое выглядит оптимальным с точки зрения номинальной модели, но оказывается неоптимальным или даже нежелательным для реального объекта.

Проблема неточности модели является особенно важной для автономных роботов. Реальная динамика системы может отличаться от расчетной по многим причинам: из-за неточно известных параметров, изменения массы, износа механических элементов, проскальзывания колес, взаимодействия с неровной поверхностью, аэродинамических эффектов,

задержек исполнительных механизмов или внешних возмущений. Даже небольшая ошибка модели может накапливаться вдоль горизонта предсказания и приводить к заметному ухудшению качества управления. Для мобильного робота это может выражаться в отклонении от заданной траектории, увеличении ошибки ориентации, появлении колебаний управления или снижении устойчивости движения на криволинейных участках.

Таким образом, возникает противоречие. С одной стороны, MPPI является удобным и гибким методом безградиентного предиктивного управления, способным работать с нелинейной динамикой и сложными функциями стоимости. С другой стороны, его эффективность во многом определяется тем, насколько точно модель, используемая внутри rollout-вычислений, описывает реальное поведение системы. Если модель неточна, то преимущество MPPI как метода прогнозирующего управления частично теряется, поскольку прогноз строится по искаженной динамике. Поэтому важной научно-технической задачей является повышение робастности MPPI к ошибкам модели.

Существующие подходы к решению этой проблемы можно условно разделить на несколько групп. Один класс методов использует дополнительную обратную связь или внешний стабилизирующий контроллер, который удерживает реальную систему вблизи номинальной траектории. В таких подходах MPPI отвечает за планирование движения по номинальной модели, а вспомогательный регулятор компенсирует отклонения реального объекта. Другой класс методов связан с оценкой параметров модели или использованием ансамбля моделей, что позволяет учитывать неопределенность динамики при выборе управления. Также широкое распространение получили подходы, основанные на обучении остаточной динамики по данным, например с использованием гауссовских процессов или нейросетевых моделей. Кроме того, существуют методы, которые повышают

безопасность за счет учета риска, распределения возможных состояний или робастных ограничений.

Каждое из этих направлений имеет свои преимущества, однако во многих случаях они требуют дополнительной структуры, предварительно собранных данных, явной параметризации неопределенности или обучения глобальной модели ошибки. Например, методы на основе гауссовских процессов позволяют не только предсказывать среднее значение невязки модели, но и оценивать неопределенность этого предсказания. Однако их применение обычно предполагает наличие обучающей выборки и отдельной процедуры обучения. Ансамблевые подходы позволяют учитывать несколько возможных моделей системы, но требуют заранее заданного набора гипотез о параметрах или структуре динамики. Внешние адаптивные контуры могут компенсировать рассогласование на уровне управляющего воздействия, но не всегда изменяют саму модель, по которой МРРІ строит будущие rollout-траектории.

В настоящей работе рассматривается другой подход к повышению робастности МРРІ. Его основная идея состоит в том, чтобы оценивать неучтенную добавочную динамику непосредственно в процессе работы контроллера и включать эту оценку в модель, используемую при построении rollout-траекторий. В отличие от методов, где компенсация добавляется только как внешний корректирующий сигнал, здесь изменяется сама прогнозная модель. Это важно, поскольку МРРІ принимает решение на основе стоимости предсказанных траекторий. Если компенсация включена в модель предсказания, то меняются не только управляющие воздействия, но и сами прогнозируемые траектории, а значит, и значения функции стоимости, на основании которых алгоритм выбирает управление.

Предлагаемый подход основан на локальной онлайн-оценке добавочного члена динамики. Предполагается, что реальное поведение системы может быть представлено как сумма номинальной модели, доступной

контроллеру, и некоторой неучтенной компоненты. Эта компонента заранее неизвестна, однако ее локальное значение можно оценить по недавно наблюдавшейся истории движения. Для этого в памяти контроллера хранится буфер последних состояний и примененных управляющих воздействий. Затем с помощью стохастической процедуры, аналогичной MPPI, генерируются кандидаты компенсационного параметра. Каждый кандидат оценивается по тому, насколько хорошо он объясняет уже наблюдавшуюся траекторию при обратном распространении динамики. Кандидаты, которые дают меньшую ошибку восстановления прошлых состояний, получают больший вес, после чего оценка компенсации обновляется как взвешенное среднее случайных возмущений.

Такой механизм сохраняет безградиентный характер исходного MPPI. Оценка выполняется локально и во время работы контроллера, то есть непосредственно во время движения системы. Это особенно важно для ситуаций, где условия работы могут изменяться. При этом локальный характер оценки учитывается с помощью фактора забывания: текущая компенсация считается наиболее достоверной вблизи текущего состояния, а ее влияние на дальних шагах горизонта предсказания постепенно уменьшается.

В качестве экспериментальной системы в данной работе рассматривается колесная мобильная платформа, движение которой описывается кинематической моделью велосипедного типа. Такая модель широко используется при анализе движения мобильных роботов и наземных транспортных средств, поскольку она достаточно проста для численных экспериментов, но при этом отражает важную связь между скоростью, углом поворота рулевого колеса и изменением ориентации. В работе исследуется ситуация, когда контроллер использует номинальное значение колесной базы, отличающееся от истинного значения в симуляторе. Это приводит к ошибке в прогнозе угла рыскания и, как следствие, к накоплению ошибки положения при движении по криволинейной траектории.

Целью данной работы является разработка и исследование модификации МРРІ, повышающей робастность управления автономным роботом при наличии неточности модели динамики за счет локальной онлайн-оценки неучтенного добавочного члена и его включения в модель предсказания rollout-траекторий.

Объектом исследования является автономная колесная мобильная платформа, движение которой описывается кинематической моделью велосипедного типа.

Предметом исследования является метод предиктивного управления МРРІ при наличии параметрического рассогласования между номинальной моделью, используемой контроллером, и реальной динамикой системы.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Проанализировать особенности применения МРРІ в задачах управления автономными робототехническими системами и определить основные причины снижения качества управления при неточности модели динамики.
2. Рассмотреть существующие подходы к повышению робастности МРРІ и компенсации ошибок модели, включая методы внешней обратной связи, оценку параметров, ансамбли моделей и обучение остаточной динамики.
3. Сформулировать модель параметрического рассогласования для колесной мобильной платформы с кинематикой велосипедного типа.
4. Разработать модификацию МРРІ, в которой неучтенная добавочная динамика оценивается локально в режиме онлайн по истории наблюдаемых состояний и примененных управляющих воздействий.

5. Включить полученную оценку добавочной динамики в модель, используемую при построении rollout-траекторий MPPI.
6. Реализовать предложенный алгоритм в численном симуляторе и провести сравнение с классическим MPPI без компенсации модели.
7. Оценить влияние фактора забывания на качество следования траектории и проанализировать полученные экспериментальные результаты по выбранным метрикам ошибки.

Научная новизна исследования заключается в использовании локальной онлайн-оценки неучтенного добавочного члена динамики непосредственно внутри прогнозной модели MPPI. В отличие от подходов, в которых компенсация ошибки модели реализуется как внешний корректирующий сигнал или требует предварительного обучения глобальной модели невязки, в данной работе компенсация уточняется во время движения системы по недавно наблюдаемой истории и используется при построении rollout-траекторий. Это позволяет изменять не только итоговое управляющее воздействие, но и сами предсказанные траектории, на основании которых MPPI вычисляет значения функции стоимости и выбирает управление.

Практическая значимость работы состоит в том, что предложенный подход может быть использован для повышения точности следования траектории автономными роботами в условиях параметрического рассогласования модели. Метод не требует вычисления градиентов и сохраняет основные преимущества MPPI, включая возможность работы с нелинейной динамикой и произвольными функциями стоимости. Кроме того, предложенная схема может быть расширена на более сложные робототехнические системы, в которых ошибка модели проявляется не только в одном параметре, но и в нескольких связанных компонентах движения.

1 Обзор литературы

Методы предиктивного управления на основе стохастической выборки траекторий получили широкое распространение в робототехнике благодаря способности работать с нелинейной динамикой, негладкими функциями стоимости и сложными ограничениями. Одним из наиболее известных подходов данного класса является Model Predictive Path Integral Control (MPPI), в котором управляющее воздействие вычисляется на основе множества случайных rollout-траекторий, получаемых добавлением шумовых возмущений к номинальной последовательности управления. Для каждой траектории вычисляется стоимость, после чего управление обновляется как взвешенное среднее, где веса имеют экспоненциальную зависимость от стоимости траектории [26]. В дальнейшем развитии данного направления задача управления формулируется через свободную энергию и KL-дивергенцию между управляемым и оптимальным распределениями траекторий [27]. Такая постановка позволяет рассматривать MPPI как общий MPC-подход, основанный на случайной выборке, применимый к широкому классу нелинейных систем, включая мобильных роботов, автономные автомобили и летательные аппараты.

Существенным преимуществом MPPI является отсутствие необходимости в вычислении градиентов. Это делает метод удобным для задач, где стоимость может включать нелинейные функции, ограничения области движения. Кроме того, MPPI подходит для параллельных вычислений, что позволяет реализовывать его в реальном времени на GPU. При этом качество данного метода существенно зависит от точности модели, используемой при вычислении rollout-траекторий. Если модель динамики отличается от реальной системы, то предсказанные траектории и соответствующие им стоимости становятся неточными, что может приводить к снижению качества управления. Эта проблема особенно заметна в агрессивных режимах движения, где даже небольшая ошибка модели быстро

накапливается вдоль горизонта вычислений. В работах [27, 29] показано, что МРРІ может успешно использовать как физически мотивированные, так и обучаемые модели динамики, однако систематическая ошибка модели остается одним из факторов, ограничивающих качество управления. Это показывает необходимость разработки методов, способных компенсировать ошибки модели в процессе работы.

Одно из направлений повышения робастности МРРІ связано с добавлением внешней обратной связи или вспомогательного контроллера. В работе [28] предложен Tube-MРРІ, где номинальная система управляется с помощью МРРІ, а реальная система удерживается в окрестности номинальной траектории за счет дополнительного контроллера. Дальнейшее развитие этой идеи представлено в работе [9], где в RМРРІ одновременно распространяются номинальная и реальная динамика, а отслеживающий контроллер включается только в вычисление rollout-траекторий. Это позволяет лучше учитывать поведение замкнутой системы и повысить устойчивость к внешним возмущениям. Похожая идея внешней компенсации рассогласования модели используется в работах [21,10], где МРРІ или NMPC дополняются L_1 -адаптивным контуром. В этих подходах предиктивный контроллер планирует движение по номинальной модели, а адаптивный компонент компенсирует расхождение между номинальной и реальной динамикой на уровне управляющего воздействия. Однако такая компенсация не изменяет саму модель, используемую при построении предсказанных траекторий, а стремится заставить реальную систему следовать номинальному поведению.

Другое направление связано с явной оценкой параметров модели или использованием ансамбля моделей. В работе [22] предложена архитектура Planner-Estimator МРРІ, в которой один МРРІ-модуль решает задачу управления, а второй выполняет оценку параметров модели в реальном времени при наличии параметрических неопределенностей. Более общая постановка задачи представлена в работе [1]. В ней МРРІ расширяется до

Ensemble MPPI: управление оптимизируется не для одной фиксированной модели, а для ансамбля физических симуляторов с различными параметрами, где вероятности гипотез истинного значения параметра обновляются в реальном времени по тому, насколько хорошо соответствующая модель предсказывает наблюдаемое поведение системы. Такие методы позволяют учитывать неопределенность физических параметров непосредственно в процессе синтеза управления, однако предполагают наличие явной параметризации неопределенности или набора возможных моделей.

Значительное число работ рассматривает коррекцию динамики, основанную на получаемых данных, с помощью регрессии гауссовского процесса. В работе [11] номинальная модель дополняется остаточной нелинейной динамикой, обучаемой с помощью гауссовского процесса (ГП). Важной особенностью является использование не только среднего значения предсказания, но и его ковариации, что позволяет формулировать ограничения, вызванные стохастическими процессами. Сходная идея применяется в работе [12], где упрощенная модель гоночного автомобиля дополняется ГП-поправкой, а неопределенность ГП используется для повышения безопасности в задаче автономных гонок. В работе [20] обучение по принципу устранения невязки через ГП объединяется с Terminal Component LMPC, где безопасные множества и терминальная стоимость формируются по данным предыдущих заездов. Для робототехнического манипулятора близкий подход предложен в работе [4]: ГП обучается заранее на ошибке модели с линеаризованной обратной связью, а дополнительное смещение оценивается в реальном времени с помощью расширенного фильтра Калмана, что обеспечивает отслеживание траектории без смещения. Эти работы показывают эффективность представления динамики в виде суммы номинальной модели и обучаемой дополнительной компоненты, однако требуют уже записанных данных и обучения ГП-модели.

Существуют также работы, в которых ГП используется непосредственно внутри МРРІ. В работе [25] для мини погрузчика ошибки линейной и угловой скоростей моделируются с помощью ГП для различных типов поверхности, а итоговая компенсация формируется как взвешенная комбинация нескольких моделей, зависящих от местности. Среднее значение ГП используется для коррекции динамики, а ковариация применяется в ограничениях при отслеживании пути и обходе препятствий. В работе [33] неопределенность ГП используется для формирования распределения выборки в МРРІ. При высокой неопределенности усиливается разведка параметров, а при низкой неопределенности алгоритм концентрируется на использовании данных, полученных при разведке. В работе [22] обученная прямая модель используется для толкательных движений, а неопределенность включается в функцию стоимости МРРІ как дополнительный штраф. В результате контроллер стремится избегать областей, где модель недостаточно уверена в своих предсказаниях. Таким образом, неопределенность модели может использоваться либо для планирования с осторожностью, либо для адаптации распределения выборки, либо как дополнительный критерий стоимости. Однако в этих подходах обычно требуется заранее обученная модель или явная оценка распределения неопределенности.

Отдельная группа работ направлена на работу с распределением траекторий и обеспечение безопасности. В работе [31] предложен СС-МРРІ, в котором распределение rollout-траекторий контролируется с помощью ковариации. Управляющее воздействие включает номинальный сигнал, случайное возмущение и обратную связь, что позволяет задавать желаемое состояние в конце горизонта вычислений. В работе [7] неопределенность состояния и динамики представляется набором частиц, для каждой из которых моделируется возможное временное развитие системы. Вводится горизонт согласованности, задающий число шагов, на которых управляющие воздействия должны быть одинаковыми для всех частиц, что позволяет

находить оптимальное решение. В работе [30] предложен Belief-Space Stochastic MPPi, где в состояние контроллера включаются математическое ожидание и ковариация, а ограничения учитываются через CBF штраф в доверительном пространстве. Эти методы повышают безопасность за счет учета распределения возможных состояний, однако не выполняют компенсации ошибки самой динамической модели.

Робастный учет параметрической неопределенности может также выполняться аналитически. В работе [17] используется чувствительность состояния к параметрам модели. На основе этой величины строятся трубки чувствительности, описывающие возможные отклонения реальной траектории от номинальной при наличии параметрической неопределенности. Эти трубки затем включаются в функцию стоимости и ограничения безопасности MPPi, например через увеличение эффективного радиуса препятствий. Такой подход не требует обучения модели, однако предполагает возможность вычисления чувствительности по параметрам и ориентирован скорее на робастность на основании худшего сценария, чем на компенсацию наблюдаемой ошибки в реальном времени. Наконец, в работе [16] ГП используется не для коррекции динамики, а для построения локального размещения и дисперсии по данным с датчиков и выбора промежуточных целей. Такой подход улучшает навигационную оценку локального MPPi-планировщика, но не изменяет модель движения робота.

Дополнительно следует отметить ряд работ, расширяющих как теоретическую основу MPPi, так и методы обучения моделей динамики для предиктивного управления. В работе [24] предложен обобщенный подход MPPi для задач обучения с подкреплением, в котором оптимальное управление вычисляется через усреднение по траекториям. Данная работа является одной из фундаментальных для последующего развития MPPi, поскольку показывает, что задачи нелинейного стохастического управления могут решаться без прямого интегрирования уравнения Гамильтона-Якоби-

Беллмана. В дальнейшем идея MPPI была развита в работе [19], где предложен более эффективный вариант управления при неопределенной динамике. В отличие от классических подходов, требующих большого числа rollout-траекторий, авторы используют вероятностное представление обученной модели динамики и двунаправленную процедуру вычислений, что позволяет получать управляющие законы с меньшим числом выборок. Эти работы важны для настоящего исследования, поскольку показывают, что стохастическое управление на основе интегралов по траекториям может быть расширено в сторону учета неопределенности модели и повышения эффективности выборки.

Наряду с робастностью и точностью модели, важной практической проблемой MPPI является гладкость управляющего сигнала. В работе [13] предложен Smooth MPPI, позволяющий получать сглаженные управляющие воздействия без внешнего фильтра над выходом работы контроллера. Авторы отмечают, что стохастическая природа MPPI может приводить к дребезгу, особенно в задачах с быстро меняющейся средой или при использовании моделей динамики, основанных на нейросетях. Для решения этой проблемы используется стратегия сдвига входных данных и измененная стоимость управления, сохраняющая структуру MPPI. Данный подход не направлен непосредственно на компенсацию ошибки модели, однако он важен с практической точки зрения, поскольку в реальных робототехнических системах точность предсказания должна сочетаться с физически реализуемыми и достаточно гладкими управляющими воздействиями.

Отдельное направление связано с учетом риска в MPPI. В работе [32] предложен Risk-Aware MPPI, использующий Conditional Value-at-Risk (CVaR) для выбора управляющих воздействий в условиях неопределенности. В отличие от стандартного MPPI, который оптимизирует среднюю стоимость траекторий, данный подход учитывает хвост распределения стоимости и тем самым делает управление более осторожным в потенциально опасных местах

траектории. Метод сохраняет возможность использования исходной нелинейной динамики и произвольных функций стоимости, что отличает его от многих классических методов стохастического MPC, требующих линеаризации или выпуклой постановки задачи. В контексте настоящей работы этот подход относится к классу методов, которые повышают безопасность за счет изменения критерия выбора траекторий, но не устраняют саму причину ошибки предсказания в модели динамики.

Существенный вклад в развитие MPC, основанного на обучении, внесен в работе [23], где предложен Learning Model Predictive Control для итеративных задач. Основная идея состоит в том, что контроллер использует данные предыдущих успешных выполнений задачи для построения безопасного множества и терминальной функции стоимости. Это позволяет улучшать качество управления от итерации к итерации и обеспечивать рекурсивную допустимость. Хотя данный подход не является MPPI и не занимается непосредственной компенсацией невязки модели динамики, он важен как пример использования накопленного опыта внутри MPC. В отличие от таких итеративных методов, настоящая работа ориентирована не на повторяющиеся заезды или накопление библиотеки успешных траекторий, а на локальную компенсацию в реальном времени текущего рассогласования модели.

Близким к рассматриваемой задаче является направление NMPC, основанного на обучении, для мобильных роботов, движущихся по сложной местности. В работе [18] предложен Robust Constrained Learning-based NMPC для надежного отслеживания траектории мобильного робота в условиях движения по пересеченной местности. Авторы используют простую модель транспортного средства и дополняют ее моделью возмущения, обучаемой с помощью ГП по данным предыдущих проходов. Такой подход позволяет предсказывать систематические отклонения от номинальной модели и учитывать ограничения безопасности. Данная работа близка по идее

компенсации ошибки модели, однако отличается тем, что использует повторяемость маршрутов и ГП-модель возмущений, обучаемую по накопленным данным, тогда как в настоящей работе рассматривается локальная оценка добавочного члена динамики без предварительного обучения глобальной модели.

Методы ГП также широко используются в более общей задаче построения предиктивных контроллеров для неизвестных нелинейных систем. В ранней работе [14] рассматривается предиктивное управление на основе ГП-моделей, где гауссовский процесс используется как вероятностная модель нелинейной динамики и позволяет получать не только среднее предсказание, но и оценку дисперсии. В работе [3] предложены варианты Gaussian Process Model Predictive Control для неизвестных нелинейных систем, где особое внимание уделяется распространению неопределенности вдоль горизонта предсказания и вычислительной реализации MPC-задачи. Эти работы дополняют уже рассмотренные GP-MPC подходы и показывают, что одна из ключевых трудностей MPC с обучением состоит не только в обучении модели, но и в корректном учете ее неопределенности на нескольких шагах прогноза

Вопрос безопасности при обучении модели динамики подробно рассматривается в работе [15]. Авторы предлагают MPC с обучением для безопасного исследования, использующий ГП-модель динамики и доверительные интервалы для предсказанных траекторий, на основе которых формулируются ограничения безопасности. Близкая идея представлена в работе [8], где предлагается общий подход к безопасности для управления с обучением в неопределенных робототехнических системах. В нем обучаемый контроллер может быть произвольным, а безопасность обеспечивается за счет критерия достижимости по Гамильтону-Якоби и минимально вмешивающегося контроллера, отвечающего за безопасность. Эти подходы показывают, что при использовании обучаемых моделей или адаптивных контроллеров необходимо отдельно решать вопрос безопасности во время

обучения и эксплуатации. В настоящей работе эта задача напрямую не рассматривается, поскольку основной акцент сделан на компенсации ошибки модели внутри rollout-вычислений MPPI, однако указанные методы могут рассматриваться как возможное направление дальнейшего расширения.

Наконец, важное значение имеют методы, основанные на обучении с подкреплением, использующие вероятностные модели динамики и распространение неопределенности. В работе [6] предложен PILCO - эффективный метод с точки зрения использования данных для поиска политики, в котором динамика системы моделируется с помощью гауссовского процесса, а неопределенность модели явно учитывается при долгосрочном прогнозировании. В работе [5] предложен PETS, объединяющий вероятностные ансамбли нейронных сетей с выборкой траекторий для распространения неопределенности в обучении с подкреплением, основанном на модели. Эти методы не являются MPPI в строгом смысле, однако они важны для понимания общей проблемы: если модель динамики неточна или ее неопределенность не учитывается, планирование по такой модели может приводить к неустойчивому поведению.

Таким образом, существующие методы повышения устойчивости и эффективности MPPI можно условно разделить на несколько классов: добавление внешней обратной связи или адаптивного контура, параметрическая оценка модели, использование ансамбля моделей, обучение модели динамики по невязке с помощью ГП или нейронных сетей, управление распределением rollout-траекторий, вероятностное ограничение состояния и учет чувствительности к параметрам модели. Большинство этих подходов либо требует предварительного обучения модели и хранения данных, либо предполагает явную параметризацию неопределенности, либо повышает безопасность за счет более осторожного планирования без исправления самой модели. В настоящей работе рассматривается иной механизм: оценка неучтенного добавочного члена динамики в реальном времени и его

непосредственное включение в модель, используемую при построении rollout-траекторий МРРІ. Такой подход сохраняет безградиентный характер МРРІ, не требует глобальной ГП-модели и направлен на локальную компенсацию текущего рассогласования реальной и номинальной модели непосредственно в процессе управления.

2 Методология

Метод Model Predictive Path Integral Control (MPPI) относится к классу стохастических методов предиктивного управления, в которых оптимизация управляющего воздействия выполняется не путем вычисления градиента функции стоимости, а за счет случайной выборки множества возможных траекторий движения. В рамках данного подхода на каждом шаге управления используется модель динамики системы, позволяющая предсказывать дальнейшее изменение состояния при различных последовательностях управляющих воздействий. После этого каждая предсказанная траектория оценивается с помощью функции стоимости, а итоговая управляющая последовательность формируется как взвешенное среднее случайных возмущений, где больший вес получают траектории с меньшей стоимостью.

Пусть состояние системы в момент времени t обозначается как x_t , а управляющее воздействие как u_t . Предполагается, что контроллеру доступна модель динамики:

$$x_{t+1} = f(x_t, u_t),$$

которая используется для построения предсказанных rollout-траекторий на конечном горизонте T . На каждом шаге работы алгоритма имеется номинальная последовательность управляющих воздействий:

$$u^{nom} = (u_0^{nom}, u_1^{nom}, \dots, u_{T-1}^{nom})$$

Для исследования окрестности данной последовательности генерируются K случайных последовательностей возмущений:

$$\delta u_t^k \sim \mathcal{N}(0, \Sigma), \quad k = 1, \dots, K, \quad t = 0, \dots, T - 1,$$

где Σ задает ковариационную матрицу распределения шума. В результате для каждой выборки k формируется управляющая последовательность:

$$u_t^k = u_t^{nom} + \delta u_t^k$$

В реализации также используется разделение выборок на эксплуатационные и разведочные. В первой части выборок шум добавляется к текущей номинальной последовательности управления, тогда как для оставшейся части выборок управление задается непосредственно шумовой последовательностью. Такой прием позволяет одновременно уточнять уже найденное решение и сохранять способность алгоритма исследовать другие области пространства управлений. Для каждой управляющей последовательности u^k выполняется прямое распространение динамики от текущего наблюдаемого состояния x_0 :

$$x_{t+1}^k = f(x_t^k, u_t^k), \quad t = 0, \dots, T - 1$$

Таким образом формируется набор траекторий:

$$\tau^k = (x_0^k, x_1^k, \dots, x_T^k), \quad k = 1, \dots, K$$

Каждой траектории ставится в соответствие интегральная стоимость:

$$S(\tau^k) = \phi(x_T^k) + \sum_{t=0}^{T-1} q(x_t^k, u_t^k),$$

где $q(x_t, u_t)$ является промежуточной стоимостью, а $\phi(x_T)$ – терминальной стоимостью. В задаче следования опорной траектории стоимость выбирается так, чтобы штрафовать отклонение текущего состояния от ближайшей точки заданной траектории. Если опорное состояние обозначить как:

$$\mathbf{x}_t^{ref} = \begin{bmatrix} x_t^{ref} \\ y_t^{ref} \\ \theta_t^{ref} \\ v_t^{ref} \end{bmatrix},$$

то промежуточная стоимость может быть записана в квадратичной форме:

$$\begin{aligned} q(x_t, u_t) = & w_x(x_t - x_t^{ref})^2 + w_y(y_t - y_t^{ref})^2 + w_\theta(\theta_t - \theta_t^{ref})^2 \\ & + w_v(v_t - v_t^{ref})^2 + q_{obs}(x_t), \end{aligned}$$

где w_x, w_y, w_θ, w_v – весовые коэффициенты, а $q_{obs}(x_t)$ – дополнительный штраф за столкновение с препятствиями. В проведенных экспериментах препятствия не использовались, однако данный член сохранен в общей постановке, поскольку он входит в структуру МРРІ-контроллера и позволяет расширять задачу на случаи движения в среде с ограничениями.

После вычисления стоимости всех траекторий формируются информационно-теоретические веса. Для повышения численной устойчивости используется минимальная стоимость:

$$\rho = \min_k S(\tau^k),$$

после чего вес k -й траектории определяется выражением:

$$\omega^k = \frac{\exp\left(-\frac{1}{\lambda}(S(\tau^k) - \rho)\right)}{\sum_{j=1}^K \exp\left(-\frac{1}{\lambda}(S(\tau^j) - \rho)\right)},$$

где λ является температурным параметром. Чем меньше значение λ , тем сильнее алгоритм концентрируется на траекториях с минимальной стоимостью. При больших значениях λ веса становятся более сглаженными, и вклад получают не только лучшие, но и близкие к ним по качеству траектории. Обновление управляющей последовательности выполняется как взвешенное среднее шумовых возмущений:

$$u_t^{new} = u_t^{nom} + \sum_{k=1}^K \omega^k \delta u_t^k, \quad t = 0, \dots, T - 1$$

В программной реализации после вычисления добавки к управлению используется фильтр скользящего среднего, сглаживающий последовательность управляющих воздействий по горизонту. Это уменьшает резкие изменения руля и ускорения, что особенно важно для кинематической модели автомобиля. После применения первого управляющего воздействия к

системе горизонт сдвигается на один шаг вперед: использованное управление удаляется, а в конец последовательности добавляется последнее значение. Далее процедура повторяется на следующем шаге управления.

Основное преимущество МРРІ состоит в том, что для синтеза управления не требуется дифференцирование модели динамики или функции стоимости. Поэтому метод может использоваться с нелинейной динамикой, негладкими штрафами и ограничениями, которые затрудняют применение градиентных методов. Однако качество МРРІ существенно зависит от того, насколько точно модель $f(x_t, u_t)$, используемая внутри rollout-вычислений, соответствует реальной системе. Если реальная динамика отличается от модели, то предсказанные траектории становятся смещенными, а вычисленные значения стоимости перестают корректно отражать будущую ошибку движения. В результате управляющее воздействие может быть оптимальным для неточной модели, но неоптимальным для реального объекта.

В данной работе рассматривается случай, когда истинная динамика системы может быть представлена в виде:

$$x_{t+1} = f(x_t, u_t) + g(x_t, u_t),$$

где $f(x_t, u_t)$ – известная контроллеру номинальная модель, а $g(x_t, u_t)$ – неучтенная добавочная часть динамики. Предлагаемый подход заключается в том, чтобы в реальном времени оценивать локальное значение этой добавочной компоненты и использовать его непосредственно в модели, по которой строятся rollout-траектории МРРІ. В отличие от подходов, основанных на предварительном обучении глобальной модели ошибки, здесь не требуется заранее собирать обучающую выборку или строить регрессионную модель для всего пространства состояний. Оценка выполняется локально, на основе недавно наблюдавшегося движения системы.

Пусть в памяти контроллера хранится последовательность последних наблюдаемых состояний:

$$\chi = (x_0, x_{-1}, \dots, x_{-T'}),$$

а также последовательность фактически примененных управляющих воздействий:

$$v = (u_0, u_{-1}, \dots, u_{-T'})$$

Здесь x_0 обозначает текущее состояние, а отрицательные индексы соответствуют предыдущим моментам времени. Длина буфера T' определяет, сколько последних измерений используется для оценки неучтенной динамики. Более длинный буфер содержит больше информации, но может включать устаревшие данные, поскольку истинное значение $g(x_t, u_t)$ зависит от текущего состояния и управления. Поэтому при вычислении стоимости используется фактор забывания.

Оценку неучтенной динамики обозначим как $\hat{g}$. Для ее обновления применяется процедура, аналогичная МРРІ, но выполняемая не в пространстве управляющих воздействий, а в пространстве возможных значений компенсационного параметра. Генерируются M случайных возмущений:

$$\delta g^m \sim \mathcal{N}(0, \Sigma_g), \quad m = 1, \dots, M$$

Для каждой выборки формируется кандидат:

$$g^m = \hat{g}^{old} + \delta g^m$$

Далее для каждого g^m выполняется обратное распространение по уже наблюдавшейся траектории. Для этого используется обратная модель $f'(x_t, u_{t-1})$, которая по текущему состоянию и ранее примененному управлению восстанавливает предыдущее состояние:

$$\hat{x}_{t-1} = f'(x_t, u_{t-1}) - g^m$$

Смысл данной операции состоит в том, что правильное значение компенсации должно позволять по текущему состоянию и известному прошлому управлению восстановить предыдущие состояния, близкие к реально наблюдавшимся. Поэтому качество каждого кандидата g^m оценивается через ошибку между восстановленной и фактически записанной историей состояний:

$$S(\tau'^m) = p \sum_{t=0}^{T'-1} \alpha^t |x_{-t-1} - \hat{x}_{-t-1}^m|^2, \quad m = 1, \dots, M,$$

где p – масштабирующий коэффициент стоимости, а α – фактор забывания, $0 < \alpha < 1$. Поскольку $t = 0$ соответствует наиболее свежему переходу, множитель α^t делает новые ошибки более значимыми, чем старые. Это важно, так как добавочная динамика $g(x_t, u_t)$ в общем случае не является постоянной на всей траектории, а лишь локально аппроксимируется текущей оценкой $\hat{g}$. По аналогии с МРРІ для каждого кандидата вычисляется вес:

$$v^m = \frac{\exp\left(-\frac{1}{\lambda_g}(S(\tau'^m) - \rho_g)\right)}{\sum_{j=1}^M \exp\left(-\frac{1}{\lambda_g}(S(\tau'^j) - \rho_g)\right)},$$

где

$$\rho_g = \min_m S(\tau'^m),$$

а λ_g – температурный параметр процедуры оценки компенсации. Затем значение оценки обновляется как взвешенное среднее возмущений:

$$\hat{g}^{new} = \hat{g}^{old} + \sum_{m=1}^M v^m \delta g^m$$

Таким образом, кандидаты компенсации, которые лучше объясняют недавно наблюдавшуюся историю движения, получают больший вес и сильнее влияют на новое значение $\hat{g}$.

В экспериментальной части работы данная идея применяется к кинематической модели колесной мобильной платформы. Состояние системы имеет вид:

$$x = \begin{bmatrix} x \\ y \\ \theta \\ v \end{bmatrix},$$

где x и y – координаты платформы на плоскости, θ – угол рыскания, v – абсолютная скорость. Управляющее воздействие задается вектором:

$$u = \begin{bmatrix} \phi \\ a \end{bmatrix},$$

где ϕ – угол поворота рулевого колеса, а a – абсолютное ускорение. Номинальная дискретная модель, используемая контроллером, записывается как:

$$\begin{cases} x_{t+1} = x_t + v_t \cos(\theta_t) dt \\ y_{t+1} = y_t + v_t \sin(\theta_t) dt \\ \theta_{t+1} = \theta_t + \frac{v_t}{\hat{l}_{wb}} \tan(\phi_t) dt \\ v_{t+1} = v_t + a_t dt \end{cases}$$

где $\hat{l}_{wb}$ – значение колесной базы, известное контроллеру. При этом реальная система имеет колесную базу l_{wb} , которая в общем случае не совпадает с $\hat{l}_{wb}$:

$$\begin{cases} x_{t+1} = x_t + v_t \cos(\theta_t) dt \\ y_{t+1} = y_t + v_t \sin(\theta_t) dt \\ \theta_{t+1} = \theta_t + \frac{v_t}{l_{wb}} \tan(\phi_t) dt \\ v_{t+1} = v_t + a_t dt \end{cases}$$

Следовательно, ошибка модели проявляется в уравнении для угла рыскания. Разность между истинной и номинальной угловой скоростью может быть записана как:

$$p(x_t, u_t) = \frac{v_t}{l_{wb}} \tan(\phi_t) - \frac{v_t}{\hat{l}_{wb}} \tan(\phi_t)$$

Тогда добавочная компонента в дискретной модели имеет вид:

$$g(x_t, u_t) = \begin{bmatrix} 0 \\ 0 \\ p(x_t, u_t) dt \\ 0 \end{bmatrix}$$

Поскольку истинное значение l_{wb} контроллеру неизвестно, величина $p(x_t, u_t)$ не может быть вычислена напрямую. Поэтому в алгоритме используется ее оценка $\hat{p}$, а соответствующая оценка добавочной динамики имеет вид:

$$\hat{g} = \begin{bmatrix} 0 \\ 0 \\ \hat{p} dt \\ 0 \end{bmatrix}$$

С учетом этой оценки модель, используемая для прямого распространения rollout-траекторий, принимает вид:

$$\begin{cases} x_{t+1} = x_t + v_t \cos(\theta_t) dt \\ y_{t+1} = y_t + v_t \sin(\theta_t) dt \\ \theta_{t+1} = \theta_t + \frac{v_t}{\hat{l}_{wb}} \tan(\phi_t) dt + \hat{p} dt \\ v_{t+1} = v_t + a_t dt \end{cases}$$

Так как оценка $\hat{p}$ является локальной и получена по последним наблюдениям, ее влияние уменьшается по мере удаления предсказания от текущего момента времени. Поэтому при построении rollout-траекторий на n -м шаге горизонта используется затухающее значение компенсации:

$$\hat{p}_n = \alpha^n \hat{p}$$

и модель прямого распространения записывается как:

$$\begin{cases} x_{t+n+1} = x_{t+n} + v_{t+n} \cos(\theta_{t+n}) dt \\ y_{t+n+1} = y_{t+n} + v_{t+n} \sin(\theta_{t+n}) dt \\ \theta_{t+n+1} = \theta_{t+n} + \frac{v_{t+n}}{\hat{l}_{wb}} \tan(\phi_{t+n}) dt + \alpha^n \hat{p} dt \\ v_{t+n+1} = v_{t+n} + a_{t+n} dt \end{cases}$$

Такое затухание отражает предположение о том, что текущая оценка неучтенной динамики наиболее достоверна вблизи текущего состояния, но ее точность снижается при прогнозировании на дальние шаги горизонта. Для обновления $\hat{p}$ используется обратная модель. Пусть известно состояние x_t и управление u_{t-1} , которое было применено на предыдущем шаге. Тогда предыдущее состояние может быть восстановлено следующим образом:

$$\begin{cases} v_{t-1} = v_t - a_{t-1} dt \\ \theta_{t-1} = \theta_t - \frac{v_{t-1}}{\hat{l}_{wb}} \tan(\phi_{t-1}) dt - \hat{p} dt \\ x_{t-1} = x_t - v_{t-1} \cos(\theta_{t-1}) dt \\ y_{t-1} = y_t - v_{t-1} \sin(\theta_{t-1}) dt \end{cases}$$

Для каждого случайного кандидата:

$$p^m = \hat{p} + \delta p^m, \quad \delta p^m \sim \mathcal{N}(0, \sigma_p^2),$$

производится обратное распространение по буферу наблюдений. Стоимость кандидата определяется по ошибке восстановления угла рыскания:

$$S_p^m = \sum_{t=0}^{T'-1} \alpha^t c_p (\theta_{-t-1} - \hat{\theta}_{-t-1}^m)^2,$$

где c_p – весовой коэффициент ошибки угла. В текущей программной реализации основной вклад в стоимость оценки параметра вносит именно ошибка по θ , поскольку рассматриваемое параметрическое рассогласование колесной базы непосредственно влияет на угловую динамику. Ошибки по координатам x и y при этом зависят от угла косвенно и могут накапливаться из-за уже имеющегося смещения ориентации, поэтому их исключение из

стоимости делает оценку более направленной на физический источник ошибки.

Веса кандидатов вычисляются по выражению:

$$v^m = \frac{\exp\left(-\frac{S_p^m - \rho_p}{\lambda_p}\right)}{\sum_{j=1}^M \exp\left(-\frac{S_p^j - \rho_p}{\lambda_p}\right)}, \quad \rho_p = \min_m S_p^m$$

После этого компенсационный параметр обновляется:

$$\hat{p}^{new} = \hat{p}^{old} + \sum_{m=1}^M v^m \delta p^m$$

Полученное значение $\hat{p}^{new}$ используется на следующем шаге работы МРРІ при построении предсказанных траекторий. Следовательно, предложенный алгоритм образует замкнутую схему: МРРІ выбирает управление по модели с текущей компенсацией, система выполняет первое управление, новое наблюдение добавляется в буфер, после чего по истории движения уточняется значение компенсации.

Полный цикл работы модифицированного алгоритма можно представить следующим образом. На каждом шаге управления контроллер получает текущее состояние системы и добавляет его в буфер наблюдений. Затем по текущему значению компенсации $\hat{p}$ выполняется стандартная МРРІ-процедура: генерируются шумовые последовательности управления, рассчитываются rollout-траектории, вычисляются стоимости и обновляется номинальная последовательность управляющих воздействий. После выбора первого управления оно сохраняется в буфере примененных воздействий. Далее, если в буфере накоплено достаточно наблюдений, выполняется обратная процедура оценки параметра: генерируются кандидаты p^m , для каждого кандидата восстанавливается предыдущая траектория, вычисляется

ошибка восстановления и обновляется $\hat{r}$. На следующем шаге обновленная оценка уже используется внутри прямых rollout-вычислений.

Таким образом, предложенная модификация MPPI не изменяет базовый принцип стохастической оптимизации управления, но дополняет его локальной онлайн-оценкой неучтенной динамики. Важной особенностью является то, что компенсация встраивается именно в модель, используемую для предсказания траекторий, а не добавляется только как внешний корректирующий сигнал к уже выбранному управлению. Это позволяет изменить сами предсказанные траектории и, следовательно, значения функции стоимости, на основании которых MPPI принимает решение. Благодаря этому алгоритм может частично компенсировать параметрическое рассогласование модели без предварительного обучения и без вычисления градиентов.

3 Экспериментальные исследования

Для проверки работоспособности предложенного подхода были проведены численные эксперименты в симуляторе движения колесной мобильной платформы. Теоретическая постановка задачи, используемая модель движения, способ внесения параметрического рассогласования и процедура оценки компенсационного члена были описаны в предыдущем разделе. Поэтому в данном разделе основное внимание уделяется экспериментальной проверке предложенного алгоритма и количественному сравнению качества управления.

Целью экспериментов являлась оценка того, насколько включение онлайн-оценки неучтенной динамики в модель, используемую внутри МРПИ, позволяет снизить ошибку следования траектории при наличии ошибки в параметре колесной базы. В качестве базового сценария рассматривалась задача движения по заданной опорной траектории. Сравнение проводилось между двумя вариантами контроллера: классическим МРПИ, использующим только номинальную модель, и МРПИ с компенсацией модели, в котором при построении rollout-траекторий учитывается текущая оценка компенсационного члена.

Общий вид используемого симулятора представлен на рисунке 1. Визуализация включает положение мобильной платформы, заданную опорную траекторию, множество rollout-траекторий, а также текущие значения управляющих воздействий. Такое представление позволяет качественно оценить поведение контроллера: видно, как распределяются предсказанные траектории, насколько фактическое движение совпадает с опорной траекторией и как изменяются управляющие воздействия в процессе движения.




Рисунок 1. Внешний вид используемого симулятора

В ходе эксперимента реальная система и модель, используемая контроллером, имели различающиеся значения колесной базы. Это рассогласование приводило к ошибке в прогнозе угла рыскания и, как следствие, к накоплению ошибки положения при движении по криволинейной траектории. Такой сценарий был выбран как простой, но показательный пример параметрической ошибки модели: источник рассогласования заранее известен при постановке эксперимента, однако контроллер не использует истинное значение параметра напрямую.

Качество управления оценивалось по ошибке следования траектории. На каждом шаге моделирования вычислялось евклидово расстояние между

текущим положением платформы и соответствующей точкой опорной траектории:

$$e_t = \sqrt{(x_t - x_t^{ref})^2 + (y_t - y_t^{ref})^2}$$

На основе последовательности ошибок e_t рассчитывались четыре метрики:

$$MSE = \frac{1}{N} \sum_{t=1}^N e_t^2,$$

$$RMSE = \sqrt{MSE},$$

$$MAE = \frac{1}{N} \sum_{t=1}^N |e_t|,$$

$$e_{max} = \max_t e_t,$$

где N – количество шагов моделирования. Метрики MSE и RMSE сильнее штрафуют крупные отклонения от траектории, MAE характеризует средний уровень ошибки, а e_{max} показывает наибольшее отклонение платформы от заданного маршрута.

Основным варьируемым параметром являлся фактор забывания α . В предложенном алгоритме он определяет, насколько долго текущая оценка неучтенной динамики сохраняет влияние при прогнозировании движения вдоль горизонта MPPI. При малых значениях α компенсация быстро затухает и практически не влияет на дальние шаги rollout-траекторий. При значениях α , близких к единице, найденная оценка используется почти на всем горизонте предсказания. Это может быть полезно при медленно меняющейся ошибке модели, но может ухудшать результат, если локальная оценка становится неточной при удалении от текущего состояния.

Результаты сравнения представлены в таблице 1. Первая строка соответствует классическому MPPI без компенсации модели. Остальные

строки соответствуют модифицированному MPPI при различных значениях фактора забывания α .

Таблица 1. Сравнение качества управления при различных значениях фактора забывания α

α	Метрики ошибки			
	MSE, м ²	RMSE, м	MAE, м	e_{max} , м
MPPI				
-	0.0652	0.2553	0.2270	0.4243
MPPI с компенсацией модели				
0.1	0.0763	0.2764	0.2454	0.4698
0.2	0.0599	0.2446	0.2134	0.4207
0.3	0.0537	0.2317	0.2030	0.3857
0.4	0.0462	0.2149	0.1820	0.3748
0.5	0.0399	0.1998	0.1715	0.3863
0.6	0.0408	0.2012	0.1743	0.3820
0.7	0.0316	0.1778	0.1502	0.3631
0.8	0.0323	0.1798	0.1466	0.3915
0.9	0.0250	0.1582	0.1160	0.3923
1.0	0.0283	0.1682	0.1279	0.4044

Из таблицы 1 видно, что при слишком малом значении фактора забывания, $\alpha = 0.1$, модифицированный алгоритм работает хуже классического MPPI. Это объясняется тем, что компенсационный член при таком значении быстро теряет влияние на прогнозируемую траекторию, но сама процедура оценки при этом остается стохастической и может вносить дополнительную вариативность в поведение контроллера. Начиная с $\alpha = 0.2$, использование компенсации приводит к улучшению качества управления по сравнению с исходным MPPI. Наилучшие значения MSE, RMSE и MAE

достигаются при $\alpha = 0.9$. В этом случае значение MSE уменьшается с 0.0652 до 0.0250, что соответствует снижению приблизительно на 61.7%. Значение MAE уменьшается с 0.2270 до 0.1160, то есть приблизительно на 48.9%. Это показывает, что учет оцененного компенсационного члена в модели rollout-траекторий позволяет существенно уменьшить среднюю ошибку следования. При этом минимальное значение максимальной ошибки достигается при $\alpha = 0.7$. Следовательно, оптимальное значение фактора забывания зависит от выбранного критерия качества. Если основной целью является снижение средней ошибки движения, то в проведенном эксперименте наилучшим является значение $\alpha = 0.9$. Если же требуется минимизировать наибольшее отклонение от траектории, то предпочтительным оказывается значение $\alpha = 0.7$. Это различие связано с тем, что более сильное сохранение компенсации вдоль горизонта улучшает среднее качество прогноза, но в отдельных участках траектории может приводить к локальному переучету текущей оценки.

Так как эксперимент проводился в симуляторе, истинное значение неучтенной динамики можно было вычислить отдельно и сравнить с оценкой, полученной предложенным алгоритмом. Такое сравнение не используется контроллером при управлении, но позволяет проанализировать, насколько корректно работает процедура онлайн-оценки. Результат сравнения представлен на рисунке 2. Из приведенного сравнения видно, что оценка в целом повторяет характер изменения истинного компенсационного члена, однако имеет заметное сглаживание и задержку. Такое поведение является ожидаемым, поскольку оценка строится на основе истории уже наблюдавшихся состояний, а не на основе прямого знания истинного параметра модели. Кроме того, стохастическое обновление и использование фактора забывания ограничивают скорость реакции оценки на быстрые изменения. Несмотря на это, полученная оценка оказывается достаточно

информативной для улучшения качества предсказания rollout-траекторий и снижения ошибки следования.




Рисунок 2. Сравнение истинного компенсационного члена и его оценки в ходе симуляции

Также на рисунке 3 показана ошибка при движении по заданной траектории для стандартного метода MPPI и для предложенного метода компенсации неточности модели при разных факторах забывания $\alpha = [0.6, 0.7, 0.8, 0.9, 1.0]$. Как видно из представленных графиков показатель MSE сохранил такое же распределение по значениям α , как и в таблице 1, при том, что графики были получены из другого запуска эксперимента. Наименьшее значение MSE достигается при $\alpha = 0.9$, также при качественном сравнении графиков видно, как с увеличением α кривая ошибки стремится к нулевому значению.

Полученные результаты показывают, что предложенный механизм компенсации наиболее эффективен при умеренно больших значениях фактора забывания. Слишком малые значения α делают компенсацию практически незначимой для MPPI, тогда как слишком большое сохранение текущей

оценки на горизонте может ухудшать отдельные показатели качества. Таким образом, фактор забывания играет роль параметра, задающего компромисс между использованием текущей оценки неучтенной динамики и осторожностью при ее распространении на будущие состояния.




Рисунок 3. Ошибка следования траектории при различных факторах забывания

В целом численные эксперименты подтверждают, что включение онлайн-оценки неучтенной динамики в модель, используемую при построении rollout-траекторий MPPI, позволяет снизить ошибку следования траектории при наличии параметрического рассогласования. Наилучшее качество по средним метрикам было получено при $\alpha = 0.9$, что показывает целесообразность использования компенсации на значительной части горизонта предсказания. При этом зависимость результатов от α показывает, что текущая оценка неучтенной динамики должна использоваться с учетом ее локального характера.

ЗАКЛЮЧЕНИЕ

В данной работе была рассмотрена задача повышения робастности стохастического предиктивного управления Model Predictive Path Integral Control при наличии неточности модели динамики мобильного робота. Актуальность данной задачи связана с тем, что MPPI, несмотря на способность работать с нелинейной динамикой, негладкими функциями стоимости и сложными ограничениями, существенно зависит от качества модели, используемой для построения rollout-траекторий. При наличии систематического рассогласования между номинальной моделью и реальной системой предсказанные траектории становятся смещенными, что приводит к ухудшению качества управления.

В ходе работы был проведен обзор существующих подходов к повышению устойчивости MPPI и близких методов предиктивного управления. Были рассмотрены методы, основанные на добавлении внешней обратной связи, адаптивных контуров, оценке параметров модели, использовании ансамблей моделей, гауссовских процессов, управлении распределением траекторий и учете неопределенности состояния. Анализ показал, что многие существующие подходы требуют предварительного обучения, явной параметризации неопределенности или дополнительной структуры робастного управления. В отличие от них, в данной работе был предложен подход, основанный на локальной онлайн-оценке неучтенной добавочной динамики и ее непосредственном включении в модель, используемую внутри MPPI.

Основная идея предложенного метода заключается в том, что ошибка модели оценивается по недавно наблюдавшейся истории движения системы. Для этого используется буфер последних состояний и примененных управляющих воздействий, а оценка компенсационного члена обновляется с помощью стохастической процедуры, аналогичной MPPI. Кандидаты компенсации оцениваются по тому, насколько хорошо они позволяют

восстановить предыдущие состояния системы при обратном распространении динамики. После этого значение компенсации обновляется как взвешенное среднее случайных возмущений. Важной особенностью метода является то, что найденная оценка используется не как внешний корректирующий сигнал, а включается непосредственно в модель, по которой рассчитываются будущие rollout-траектории. Благодаря этому изменяются сами предсказания движения и соответствующие значения функции стоимости, на основании которых MPPИ выбирает управление.

Для экспериментальной проверки предложенный подход был применен к задаче следования заданной траектории колесной мобильной платформой. В качестве источника рассогласования рассматривалась ошибка в параметре колесной базы: реальная система и модель, доступная контроллеру, имели различные значения данного параметра. Такое рассогласование приводило к ошибке в прогнозе угла рыскания и, как следствие, к накоплению ошибки положения при движении по криволинейной траектории. Сравнение проводилось между классическим MPPИ и модифицированным MPPИ с компенсацией модели.

Результаты численных экспериментов показали, что включение онлайн-оценки неучтенной динамики позволяет заметно снизить ошибку следования траектории. При слишком малом значении фактора забывания компенсация быстро теряет влияние на прогноз и не дает улучшения по сравнению с базовым MPPИ. Однако при умеренных и больших значениях фактора забывания модифицированный алгоритм демонстрирует более высокое качество управления. Наилучшие значения среднеквадратичной ошибки, RMSE и средней абсолютной ошибки были получены при $\alpha = 0.9$. В этом случае значение MSE снизилось с 0.0652 до 0.0250, а MAE – с 0.2270 до 0.1160. Это подтверждает, что учет оцененного компенсационного члена в модели rollout-траекторий позволяет существенно уменьшить среднюю ошибку движения. При этом минимальное значение максимальной ошибки было

достигнуто при $\alpha = 0.7$, что указывает на зависимость оптимального значения фактора забывания от выбранного критерия качества.

Дополнительный анализ оценки компенсационного члена показал, что она в целом повторяет характер изменения истинной неучтенной динамики, хотя имеет сглаживание и задержку. Такое поведение является ожидаемым, поскольку оценка строится только по наблюдаемой истории движения и не использует истинное значение параметра модели. Несмотря на это, полученная оценка оказалась достаточно информативной для улучшения качества предсказания и повышения точности следования траектории.

Таким образом, в работе был предложен и проверен метод локальной компенсации ошибки модели для MPPI, который сохраняет безградиентный характер исходного алгоритма, не требует предварительного обучения глобальной модели ошибки и может работать в онлайн-режиме. Полученные результаты подтверждают, что непосредственное включение оценки неучтенной динамики в модель предсказания является перспективным способом повышения робастности MPPI при параметрическом рассогласовании.

В дальнейшем предложенный подход может быть расширен и проверен в более сложных условиях. В частности, целесообразно провести серию экспериментов при различных величинах ошибки модели, на различных типах опорных траекторий и при наличии шума измерений состояния. Также важным направлением является анализ устойчивости метода при нескольких запусках, поскольку MPPI относится к стохастическим методам управления. Кроме того, предложенный принцип компенсации может быть обобщен на более сложные модели мобильных роботов, летательных аппаратов и манипуляторов, где неучтенная динамика может затрагивать не один параметр, а несколько связанных компонент движения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Abraham I. et al. Model-based generalization under parameter uncertainty using path integral control //IEEE Robotics and Automation Letters. – 2020. – Т. 5. – №. 2. – С. 2864-2871.
2. Arruda E. et al. Uncertainty averse pushing with model predictive path integral control //2017 IEEE-RAS 17th International Conference on Humanoid Robotics (Humanoids). – IEEE, 2017. – С. 497-502.
3. Cao G., Lai E. M. K., Alam F. Gaussian process model predictive control of unknown non-linear systems //IET Control Theory & Applications. – 2017. – Т. 11. – №. 5. – С. 703-713.
4. Carron A. et al. Data-driven model predictive control for trajectory tracking with a robotic arm //IEEE Robotics and Automation Letters. – 2019. – Т. 4. – №. 4. – С. 3758-3765.
5. Chua K. et al. Deep reinforcement learning in a handful of trials using probabilistic dynamics models //Advances in neural information processing systems. – 2018. – Т. 31.
6. Deisenroth M., Rasmussen C. E. PILCO: A model-based and data-efficient approach to policy search //Proceedings of the 28th International Conference on machine learning (ICML-11). – 2011. – С. 465-472.
7. Dyro R. et al. Particle MPC for uncertain and learning-based control //2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). – IEEE, 2021. – С. 7127-7134.
8. Fisac J. F. et al. A general safety framework for learning-based control in uncertain robotic systems //IEEE Transactions on Automatic Control. – 2018. – Т. 64. – №. 7. – С. 2737-2752.
9. Gandhi M. S. et al. Robust model predictive path integral control: Analysis and performance guarantees //IEEE Robotics and Automation Letters. – 2021. – Т. 6. – №. 2. – С. 1423-1430.

10. Hanover D. et al. Performance, precision, and payloads: Adaptive nonlinear mpc for quadrotors //IEEE Robotics and Automation Letters. – 2021. – T. 7. – №. 2. – C. 690-697.
11. Hewing L., Kabzan J., Zeilinger M. N. Cautious model predictive control using gaussian process regression //IEEE Transactions on Control Systems Technology. – 2019. – T. 28. – №. 6. – C. 2736-2743.
12. Kabzan J. et al. Learning-based model predictive control for autonomous racing //IEEE Robotics and Automation Letters. – 2019. – T. 4. – №. 4. – C. 3363-3370.
13. Kim T. et al. Smooth model predictive path integral control without smoothing //IEEE Robotics and Automation Letters. – 2022. – T. 7. – №. 4. – C. 10406-10413.
14. Kocijan J. et al. Predictive control with Gaussian process models //The IEEE Region 8 EUROCON 2003. Computer as a Tool. – IEEE, 2003. – T. 1. – C. 352-356.
15. Koller T. et al. Learning-based model predictive control for safe exploration //2018 IEEE conference on decision and control (CDC). – IEEE, 2018. – C. 6059-6066.
16. Mohamed I. S., Ali M., Liu L. Gp-guided mppi for efficient navigation in complex unknown cluttered environments //2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). – IEEE, 2023. – C. 7463-7470.
17. Nyboe F. F. et al. Embedded Robust Model Predictive Path Integral Control using Sensitivity Tubes and GPU Acceleration //2025 IEEE International Conference on Robotics and Automation (ICRA). – IEEE, 2025. – C. 7174-7180.
18. Ostafew C. J., Schoellig A. P., Barfoot T. D. Robust constrained learning-based NMPC enabling reliable mobile robot path tracking //The International Journal of Robotics Research. – 2016. – T. 35. – №. 13. – C. 1547-1563.

19. Pan Y., Theodorou E., Kontitsis M. Sample efficient path integral control under uncertainty //Advances in Neural Information Processing Systems. – 2015. – T. 28.
20. Pinho J. et al. Learning-based model predictive control for autonomous racing //World Electric Vehicle Journal. – 2023. – T. 14. – №. 7. – C. 163.
21. Pravitra J. et al. $\mathcal{L}^1$ -adaptive mppi architecture for robust and agile control of multirotors //2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). – IEEE, 2020. – C. 7661-7666.
22. Raisi M., Noohian A., Fallah S. A fault-tolerant and robust controller using model predictive path integral control for free-flying space robots //Frontiers in Robotics and AI. – 2022. – T. 9. – C. 1027918.
23. Rosolia U., Borrelli F. Learning model predictive control for iterative tasks. a data-driven control framework //IEEE Transactions on Automatic Control. – 2017. – T. 63. – №. 7. – C. 1883-1896.
24. Theodorou E., Buchli J., Schaal S. A generalized path integral control approach to reinforcement learning //The Journal of Machine Learning Research. – 2010. – T. 11. – C. 3137-3181.
25. Trivedi A. et al. Data-driven sampling based stochastic MPC for skid-steer mobile robot navigation //2025 IEEE International Conference on Robotics and Automation (ICRA). – IEEE, 2025. – C. 16619-16625.
26. Williams G., Aldrich A., Theodorou E. A. Model predictive path integral control: From theory to parallel computation //Journal of Guidance, Control, and Dynamics. – 2017. – T. 40. – №. 2. – C. 344-357.
27. Williams G. et al. Information-theoretic model predictive control: Theory and applications to autonomous driving //IEEE Transactions on Robotics. – 2018. – T. 34. – №. 6. – C. 1603-1622.
28. Williams G. et al. Robust Sampling Based Model Predictive Control with Sparse Objective Information //Robotics: Science and Systems. – 2018. – T. 14. – C. 2018.

29. Williams G. et al. Information theoretic MPC for model-based reinforcement learning //2017 IEEE international conference on robotics and automation (ICRA). – IEEE, 2017. – C. 1714-1721.
30. Yin J., Tsiotras P., Berntorp K. Chance-constrained information-theoretic stochastic model predictive control with safety shielding //2024 IEEE 63rd Conference on Decision and Control (CDC). – IEEE, 2024. – C. 653-658.
31. Yin J. et al. Trajectory distribution control for model predictive path integral control using covariance steering //2022 International Conference on Robotics and Automation (ICRA). – IEEE, 2022. – C. 1478-1484.
32. Yin J., Zhang Z., Tsiotras P. Risk-aware model predictive path integral control using conditional value-at-risk //2023 IEEE International Conference on Robotics and Automation (ICRA). – IEEE, 2023. – C. 7937-7943.
33. Yoon D. et al. Uncertainty-Aware adaptive sampling in MPPI for robust UAV path-Following //Aerospace Science and Technology. – 2025. – C. 111126.